

FAKULTA INFORMAČNÍCH TECHNOLOGIÍ VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ

SFC – Projekt 10 – Autoencoder Deep Neural Network

27.11.2023


Matúš Remeň (xremen01)

1 Úvod

Autoenkodér je druh hlbkej doprednej neurónovej siete, ktorá je trénovaná aby na svojom výstupe reprezentovala čo najlepšie svoj vstup. Skladá sa z jednej skrytej vrstvy a jednej výstupnej vrstvy perceptronov. Dalo by sa povedať, že skrytá vrstva funguje ako kodér, ktorá reprezentuje funkciu *encode* a jej výstupom je kód – c (1). Výstupná vrstva sa potom snaží rekonštruovať kód – c – späť na vstup kodéru. Dekodér vykonáva funkciu *decode* z rovnice (1).

$$\begin{aligned}c &= \text{encode}(x) \\ r &= \text{decode}(c) \\ r &\approx x\end{aligned}\tag{1}$$

Na obrázku 1 je zobrazená vzorová neurónová sieť typu autoenkodér. Vstupná a výstupná vrstva má veľkosť vstupného vektora $\vec{x}$. Čiže platí $||\vec{x}|| = ||\vec{y}||$. Keby sa táto neurónová sieť naučila dokonalo reprezentovať vstup na výstupe, nebolo by to veľmi užitočné : $x = \text{decode}(\text{encode}(x))$. Kvôli tomu je autoenkodér navrhnutý tak, aby nedokázal vykonávať túto funkciu dokonale, ale aby ju len aproximoval. Vďaka obmedzeniam, sa táto sieť často naučí dôležité vlastnosti z trénovacích dát. [2]



Obr. 1: Príklad neurónovej siete – Autoenkodér.

Autoenkodér sa preto často používa na predtrénovanie hlbokých viacvrstvých neurónových sietí, na počiatočné nastavenie váh. Predtrénovanie prebieha poustupným dosádzovaním vrstiev hlbkej siete za skrytú vrstvu autoenkodéru. Vstupná a výstupná vrstva sa nastaví podľa veľkosti výstupu predchádzajúcej vrstvy v pripravovanej hlbkej neurónovej sieti. Následne sa spustí tréning pomocou klasického algoritmu *backpropagation* alebo jeho modifikácií. Vypočítané váhy skrytej vrstvy sa následne nastavujú do pripravovanej siete. Výstupná vrstva sa už ďalej nepoužíva a v ďalšej iterácii sa inicializuje nanovo. [1]

Cieľom tohto projektu je demonštrovať učenie neurónovej siete typu autoenkodér. Pre tento účel som si zvolil dátovú sadu obrázkov ručne písaných čísl z databázy MNIST¹.

¹<https://www.fit.vutbr.cz/study/courses/SFC/private/benchmarks/mnist/mnist.zip>


2 Implementácia

Ako implementačný jazyk som si zvolil *Python 3* kvoli osobným preferenciám a vhodnosti pre nasledujúce požiadavky. V rámci tejto práce som implementoval autoenkodér len za využitia knižnice *numpy* a jednoduché webové užívateľské rozhranie pomocou knižnice *flask*. Dodatočne pre vykresľovanie grafov a obrázkov som použil knižnice *matplotlib* a *imageio*.

Webové užívateľské rozhranie pozostáva z dvoch stránok implementovaných v jazyku *HTML* ako šablóny, ktoré sú parametrizované a vykreslené pomocou *flask* aplikácie. Prvá stránka, viditeľná na obrázku 2 slúži na konfiguráciu autoenkodéru, menovite je sa jedná o tieto parametre modelu a jeho učenia:

- `hidden_layer_size` – určuje počet perceptronov v skrytej vrstve
- `hidden_layer_activation` – určuje aktivačnú funkciu perceptronov v skrytej vrstve
- `epochs` – určuje počet *epoch* učenia
- `learning_rate` – koeficient učenia

Soft Computing - Demonstration of Autoencoder Deep Neural Network Training



The screenshot shows a web form with the following elements:

- Hidden Layer Size:** A text input field containing the value '128'.
- Epochs:** A text input field containing the value '10'.
- Learning Rate:** A text input field containing the value '0.2'.
- Activation Function of the Hidden Layer:** A dropdown menu with 'ReLU' selected and a blue icon to its right.
- Train:** A button located at the bottom of the form.

Obr. 2: Titulná stránka aplikácie.

Po kliknutí na tlačítko *Train* na prvej stránke sa zobrazí stránka, na ktorej možno riadiť a sledovať postup trénovania modelu. Náhľad tejto stránky je viditeľný na obrázku 3. Dodatočne na tejto stránke je možné otestovať daný model na ľubovoľne zvolenom obrázku, ktorý je v rovnakom formáte ako trénovacie dáta – čierno-biele obrázky veľkosti 28x28 vo formáte *GIF*. Tlačidlo *All Epochs* spustí celé učenie modelu. Pomocou tlačidla *One Epoch* možno trénovať model po krokoch a hocikedy medzitým ho testovať na obrázkoch v správnom formáte.

Na obrázku 3 je obsahuje model na skrytej vrstve 128 perceptronov s aktivačnou funkciou *ReLU*, s koeficientom učenia 0.02 a počtom epoch 5. Pod tabuľkou, ktorá popisuje aktuálny model je vykreslený graf, ktorý zobrazuje priebeh učenia modelu. Tento graf je zobrazený aj na obrázku 5. Výstup funkcionality voliteľného testovania modelu, je viditeľný na obrázku 4.


Model autoenkodéru, базовые функции и активационные функции som implementoval za využitia knižovne *numpy*. Pre skrytú vrstvu modelu je dostupná voľba aktivačnej funkcie *ReLU* alebo *Sigmoid*. Na výstupnej vrstve sa používa len aktivačná funkcia *Sigmoid*. Všetky perceptrony v sieti používajú lineárnu базовую функцию. Učenie modelu prebieha pomocou metódy Mini-batch gradient descend.

Autoencoder Neural Network Training

Configuration

Config Name	Config Value
hidden_layer_size	128
epochs	5
learning_rate	0.02
hidden_layer_activation	ReLU

Training Progress



Obr. 3: Stránka aplikácie, kde možno riadiť učenie modelu.

Original image





Image from the autoencoder



Obr. 4: Testovanie modelu na ľubovoľnom obrázku z dátovej sady.

3 Inštalácia a spustenie


Za predpokladu, že programovací jazyk *Python 3* je nainštalovaný, pre nainštalovanie vyžadovaných knižníc stačí spustiť príkaz:

```
pip3 install -r requirements.txt
```

Nasledovne webová aplikácia sa spustí príkazom:

```
python3 app.py
```

Potom stačí už len v prehliadači navštíviť stránku na *localhost* url `http://127.0.0.1:5000/`, kde je aplikácia dostupná.



Obr. 5: Graf učenia vzorového modelu.

Literatúra

- [1] *Acyklické a dopředné neuronové sítě. Algoritmus backpropagation* [https://www.fit.vutbr.cz/study/courses/SFC/private/zboril2020/20sfc_2.pdf]. 2020. Prednáška č. 2.
- [2] GOODFELLOW, I., BENGIO, Y. a COURVILLE, A. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.